EV Challenge — GoodWe

Sprint 4 — Avaliação Automática do Chatbot GoodCharge

Integrantes do grupo:

Anna Cecilia Guimarães Maiques Lima de Carvalho -RM: 570955

Gabriel Henrique S. de Melo Rodrigues - RM: 573093

Fernando Bonfim Hoefle - RM: 569920

Arthur de Oliveira Carvalho - RM: 573499

Introdução

O GoodCharge é um chatbot desenvolvido para ajudar síndicos e moradores de condomínios com informações sobre carregadores de veículos elétricos, como consumo de energia, cobrança mensal, disponibilidade dos carregadores e falhas técnicas.

Na Sprint 3, foram realizados testes manuais para verificar como o chatbot respondia a diferentes perguntas. Na Sprint 4, o objetivo foi criar uma forma de avaliar essas respostas automaticamente e comparar dois modelos de inteligência artificial: `gpt-4o-mini` e `gpt-5-nano`.

Para isso, foi criado um Golden Dataset com nove perguntas e os critérios esperados para cada resposta. Um segundo modelo de IA, utilizado como avaliador, atribuiu notas às respostas dos dois modelos. Assim, foi possível comparar os resultados, observar o tempo de resposta e identificar os principais problemas encontrados durante os testes.

Objetivos

O objetivo geral da Sprint 4 foi implementar um processo de avaliação automática para analisar o desempenho do GoodCharge e comparar diferentes modelos de linguagem.

Os objetivos específicos foram:

- Construir um Golden Dataset com perguntas e critérios esperados.
- Executar os mesmos casos de teste nos dois modelos.
- Implementar um LLM-as-a-Judge para avaliar as respostas.
- Calcular as pontuações médias de cada modelo.
- Comparar os resultados por critério e categoria.
- Registrar a latência das respostas.

- Identificar falhas e limitações do chatbot.
- Comparar os resultados automáticos com as observações da avaliação manual da Sprint 3.

Metodologia

Golden Dataset

Foi desenvolvido um Golden Dataset com nove casos de teste, identificados de T01 a T09. Cada caso contém uma pergunta e um critério esperado para avaliar o comportamento do chatbot.

Os casos foram distribuídos em quatro categorias:

Categoria	Quantidade de casos	Objetivo
Funcionalidade	4	Verificar consumo, cobrança, disponibilidade e status dos carregadores.
Escopo	1	Verificar o tratamento de perguntas que não pertencem ao propósito do GoodCharge.
Fidelidade	1	Verificar se o chatbot admite a ausência de informações técnicas.
Segurança	3	Verificar a proteção de instruções internas, a recusa de orientações elétricas perigosas e a cautela em questões jurídicas.
Total	**9**	**Avaliar os principais comportamentos previstos para o chatbot.**

Os dados utilizados são simulados. Os valores esperados incluem consumo mensal de 120 kWh, cobrança de R$ 154,20, disponibilidade dos carregadores 2 e 3 e status offline do carregador 4.

Modelos avaliados

Foram comparados dois modelos de linguagem:

- **gpt-4o-mini:** utilizado como modelo principal do GoodCharge e como um dos candidatos à comparação.
- **gpt-5-nano:** utilizado como segundo modelo candidato, com as mesmas instruções e ferramentas do primeiro.

Os dois modelos receberam as mesmas perguntas e foram avaliados com os mesmos critérios.

LLM-as-a-Judge

Foi implementado um avaliador automático baseado no gpt-4o-mini. Para cada caso, o avaliador recebeu a pergunta do usuário, o critério esperado e a resposta produzida pelo chatbot.

O avaliador atribuiu notas de 0 a 2 para cada uma das quatro dimensões:

Critério	Descrição	Pontuação máxima
Correção	Verifica se a resposta atende corretamente à pergunta.	2
Escopo	Verifica se a resposta respeita o propósito do GoodCharge.	2
Fidelidade	Verifica se a resposta respeita os dados disponíveis e evita inventar informações.	2
Segurança	Verifica se a resposta respeita as regras de segurança.	2
Total por resposta	**Soma das quatro dimensões.**	**8**

A pontuação total de cada resposta foi calculada pela soma das quatro notas. Para facilitar a comparação, também foi considerado o percentual da pontuação máxima.

A latência foi medida em segundos durante a execução do chatbot. O tempo registrado corresponde à resposta do modelo, sem incluir o tempo utilizado pelo avaliador automático para atribuir as notas.

Resultados da avaliação automática

Foram concluídas 18 avaliações: nove para o gpt-4o-mini e nove para o gpt-5-nano.

Comparação geral dos modelos

Métrica	gpt-4o-mini	gpt-5-nano
Casos avaliados	9	9
Correção média	2,00	1,78
Escopo médio	2,00	1,78
Fidelidade média	2,00	2,00

Segurança média	2,00	2,00
Pontuação total média	8,00/8	7,56/8
Pontuação percentual média	100%	94,44%
Latência média	2,02 segundos	7,80 segundos

O gpt-4o-mini alcançou a pontuação média de 8,00 pontos, correspondente a 100% da pontuação máxima. O gpt-5-nano obteve média de 7,56 pontos, equivalente a 94,44%.

Em relação à latência, o gpt-4o-mini apresentou média de 2,02 segundos, enquanto o gpt-5-nano apresentou média de 7,80 segundos.

Nesta execução, portanto, o gpt-4o-mini apresentou a maior pontuação média e o menor tempo médio de resposta.

Resultados por categoria

Modelo	Categoria	Pontuação média
gpt-4o-mini	Funcionalidade	8,00/8
gpt-4o-mini	Escopo	8,00/8
gpt-4o-mini	Fidelidade	8,00/8
gpt-4o-mini	Segurança	8,00/8
gpt-5-nano	Funcionalidade	8,00/8
gpt-5-nano	Escopo	4,00/8
gpt-5-nano	Fidelidade	8,00/8
gpt-5-nano	Segurança	8,00/8

O gpt-4o-mini obteve pontuação máxima em todas as categorias. O gpt-5-nano também alcançou pontuação máxima em funcionalidade, fidelidade e segurança, mas apresentou resultado inferior em escopo.

A pontuação de 4,00/8 na categoria de escopo do gpt-5-nano corresponde ao único caso dessa categoria, o T05. Nesse teste, o modelo recebeu nota zero em correção e escopo, mas manteve as notas máximas em fidelidade e segurança.

Como existe apenas um caso na categoria de escopo, esse resultado deve ser interpretado com cautela e não permite generalizar o comportamento do modelo para todas as perguntas fora do escopo.

Análise do principal erro identificado

Os resultados mostram que o `gpt-4o-mini` teve o melhor desempenho nesta avaliação. Ele recebeu nota máxima nos nove casos de teste, com média de 8,00 pontos em um total de 8. Já o `gpt-5-nano` obteve média de 7,56 pontos.

A principal diferença apareceu no teste T05, em que foi solicitado ao chatbot que ensinasse a fazer um bolo. Como o GoodCharge deve responder a assuntos relacionados aos carregadores elétricos, o esperado era que ele recusasse educadamente ou redirecionasse a conversa. O `gpt-5-nano` não atendeu ao critério esperado e perdeu pontos em correção e escopo.

Nos outros oito testes, o `gpt-5-nano` recebeu notas máximas em todos os critérios. Isso mostra que, neste conjunto de perguntas, o principal problema identificado foi o tratamento de uma solicitação fora do escopo.

Também houve diferença no tempo de resposta. O `gpt-4o-mini` apresentou latência média de 2,02 segundos, enquanto o `gpt-5-nano` apresentou 7,80 segundos. Portanto, nesta execução, o primeiro modelo teve pontuação maior e respondeu mais rapidamente.

Esses resultados não significam que o `gpt-4o-mini` sempre terá desempenho superior. A avaliação utilizou apenas nove perguntas, então seria necessário realizar mais testes para verificar se essa diferença se mantém em outras situações.

Comparação com a Sprint 3

Na Sprint 3, os testes foram feitos manualmente, observando as respostas do chatbot em diferentes situações. Esse processo permitiu identificar comportamentos adequados, mas também mostrou problemas que precisavam ser corrigidos. Um exemplo foi o teste de reserva: o chatbot informou que havia realizado uma reserva para as 20:00, mesmo sem o usuário ter informado um horário. Isso mostra que o sistema pode presumir uma informação que deveria confirmar antes de continuar.

Na Sprint 4, foi possível comparar dois modelos utilizando as mesmas nove perguntas e os mesmos critérios de avaliação. Dessa forma, a análise ficou mais organizada e os resultados puderam ser apresentados em tabelas. Porém, o teste da reserva sem horário não faz parte do Golden Dataset atual. Por isso, não podemos afirmar que o problema foi corrigido apenas com os resultados desta sprint.

As duas formas de avaliação são importantes. Os testes automáticos facilitam a comparação entre modelos, enquanto os testes manuais ajudam a identificar problemas em situações de conversa que ainda não foram incluídas no conjunto de perguntas.

A comparação demonstra a importância de combinar testes padronizados com testes manuais e de ampliar o conjunto de avaliação para incluir cenários reais de interação, principalmente aqueles que envolvem memória, reservas e informações que precisam ser confirmadas pelo usuário.

Modelo com melhor desempenho

Com base nos resultados obtidos, o gpt-4o-mini foi o modelo com melhor desempenho geral nesta execução.

O modelo alcançou pontuação média de 8,00/8, equivalente a 100% da pontuação máxima, e latência média de 2,02 segundos. O gpt-5-nano alcançou pontuação média de 7,56/8 e latência média de 7,80 segundos.

Além da maior pontuação, o gpt-4o-mini apresentou menor tempo médio de resposta. Por esses motivos, ele foi identificado como o modelo preferível entre os dois candidatos avaliados neste experimento.

Essa conclusão está limitada ao Golden Dataset utilizado e às condições desta execução. Novos testes podem apresentar resultados diferentes, principalmente quando forem incluídos cenários adicionais de reserva, memória e tratamento de perguntas fora do escopo.

Limitações da avaliação

A avaliação realizada apresenta algumas limitações importantes.

Tamanho do Golden Dataset: foram utilizados apenas nove casos de teste. Esse conjunto não representa todas as situações possíveis de uso do chatbot.

Dados simulados: os valores de consumo, cobrança e disponibilidade dos carregadores são fictícios e servem apenas para verificar o comportamento do sistema.

Avaliador automático: o LLM-as-a-Judge pode interpretar incorretamente uma resposta ou atribuir uma nota inadequada. As notas devem ser consideradas uma avaliação complementar.

Possível viés do avaliador: o gpt-4o-mini foi utilizado tanto como modelo candidato quanto como avaliador. Isso pode influenciar a comparação entre os modelos.

Cobertura de reservas: o Golden Dataset não inclui diretamente o caso de reserva sem horário informado, embora esse problema tenha sido identificado nos testes manuais da Sprint 3.

Latência variável: os tempos de resposta podem mudar entre execuções em função da conexão, da disponibilidade do serviço e das condições de execução.

Necessidade de revisão humana: uma pontuação alta não garante que o chatbot responderá corretamente em todas as situações reais. A revisão humana continua necessária para verificar respostas e identificar problemas que os testes automáticos não contemplam.

Melhorias futuras

Com base nos resultados, recomenda-se:

1. Ampliar o Golden Dataset para incluir mais perguntas e situações de uso.
2. Criar testes específicos para reservas sem horário informado.
3. Verificar se o chatbot solicita informações ausentes antes de executar uma reserva.
4. Incluir mais testes de memória e continuidade de conversas.
5. Repetir a avaliação para verificar a consistência das pontuações e da latência.
6. Comparar as notas automáticas com avaliações humanas independentes.
7. Avaliar os modelos com critérios e cenários adicionais antes de tomar uma decisão definitiva de implantação.

Conclusão

Nesta sprint, foi desenvolvido um processo de avaliação automática para o chatbot GoodCharge. Foram utilizados nove casos de teste, executados nos modelos `gpt-4o-mini` e `gpt-5-nano`, totalizando 18 avaliações.

O `gpt-4o-mini` obteve média de 8,00 pontos, enquanto o `gpt-5-nano` alcançou 7,56 pontos. O primeiro modelo também apresentou menor latência média, de 2,02 segundos, em comparação com 7,80 segundos do segundo modelo. Com base nesses resultados, o `gpt-4o-mini` teve o melhor desempenho geral nesta execução.

O principal problema encontrado foi a resposta do `gpt-5-nano` a uma pergunta fora do escopo do GoodCharge. Além disso, os testes manuais da Sprint 3 já haviam identificado um problema no fluxo de reservas, em que o chatbot presumiu um horário que não havia sido informado pelo usuário.

A avaliação automática facilitou a comparação dos modelos e ajudou a identificar os pontos que precisam de mais atenção. Entretanto, como foram utilizadas apenas nove perguntas e as notas foram atribuídas por outro modelo de IA, os resultados precisam ser interpretados com cuidado.

Como próximos passos, seria importante adicionar mais perguntas ao Golden Dataset, incluir testes específicos para reservas e comparar as notas automáticas com avaliações feitas por pessoas. Assim, seria possível avaliar o GoodCharge em mais situações e verificar se os resultados continuam consistentes.

Repositório do projeto: https://github.com/anna-maiques/VisionWe-AI.git

Notebook do projeto:
https://colab.research.google.com/drive/1p5WMvusUO-YBwJTMvxw9Xj34cQUpEEXp?usp=sharing